Практическое задание №1

Установка необходимых пакетов:

```
!pip install -q tqdm
!pip install --upgrade --no-cache-dir gdown
```

```
Requirement already satisfied: gdown in /usr/local/lib/python3.10/dist-packages (4.6.6)
Collecting gdown
  Downloading gdown-4.7.1-py3-none-any.whl (15 kB)
Requirement already satisfied: filelock in /usr/local/lib/python3.10/dist-packages (from gdown) (3.13.1)
Requirement already satisfied: requests[socks] in /usr/local/lib/python3.10/dist-packages (from gdown) (2.31.0)
Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages (from gdown) (1.16.0)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from gdown) (4.66.1)
Requirement already satisfied: beautifulsoup4 in /usr/local/lib/python3.10/dist-packages (from gdown) (4.11.2)
Requirement already satisfied: soupsieve>1.2 in /usr/local/lib/python3.10/dist-packages (from beautifulsoup4->gdown) (2.5)
Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.10/dist-packages (from requests[socks]->gdown) (3
Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.10/dist-packages (from requests[socks]->gdown) (3.6)
Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.10/dist-packages (from requests[socks]->gdown) (2.0.7)
Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/dist-packages (from requests[socks]->gdown) (2023.11
Requirement already satisfied: PySocks!=1.5.7,>=1.5.6 in /usr/local/lib/python3.10/dist-packages (from requests[socks]->gdown) (1.7
Installing collected packages: gdown
  Attempting uninstall: gdown
    Found existing installation: gdown 4.6.6
    Uninstalling gdown-4.6.6:
      Successfully uninstalled gdown-4.6.6
Successfully installed gdown-4.7.1
```

Монтирование Вашего Google Drive к текущему окружению:

```
from google.colab import drive
drive.mount('/content/drive', force_remount=True)
```

```
Mounted at /content/drive
```

Константы, которые пригодятся в коде далее, и ссылки (gdrive идентификаторы) на предоставляемые наборы данных:

```
EVALUATE_ONLY = True
TEST_ON_LARGE_DATASET = True
TISSUE_CLASSES = ('ADI', 'BACK', 'DEB', 'LYM', 'MUC', 'MUS', 'NORM', 'STR', 'TUM')
DATASETS_LINKS = {
    'train': '1XtQzVQ5XbrfxpLHJuL0XBGJ5U7CS-cLi',
    'train_small': '1qd45xXfDwdZjktLFwQb-et-mAaFeCzOR',
    'train_tiny': '16pOe_-513PgIDVLbqQN1znTLbBYCKSnE',
    'test': '1RfPou3pFKpuHDJZ-D9XDFzgvwpUBFlDr',
    'test_small': '1wbRsog0n7uGlHIPGLhyN-PMeT2kdQ2lI',
    'test_tiny': '1viiB0s041CNsAK4itvX8PnYthJ-MDnQc'
}
```

```
MY_DATASETS_LINKS = {
    'train_small': '1enj3quiGzgGT_y2kbjeQAKETBkEU6ZwC',
    'train_tiny': '1zKHqhZwsA1apanAmjEAxjptReTM3YGkl',
    'train': '1it3d8vuvpB_7jUQsxJHt6i395PTOV76s',
    'test_small': '17NAF4NKc8ZBy69N6r3I_GAuikju3-qdb',
    'test_tiny': '1uBCol9lBCwIm_T585x-TL1NKqN2WYZKH',
    'test': '1J8gzUaLSBnO1VRYqUPm818mJzA-oAL9v'
}
```

Импорт необходимых зависимостей:

```
from pathlib import Path
import numpy as np
from typing import List
from tqdm.notebook import tqdm
from time import sleep
from PIL import Image
import IPython.display
from sklearn.metrics import balanced_accuracy_score
import gdown
import tensorflow as tf
import matplotlib.pyplot as plt
```

Класс Dataset

Предназначен для работы с наборами данных, обеспечивает чтение изображений и соответствующих меток, а также формирование пакетов (батчей).

[ ] *Скрыта 1 ячейка.*

Пример использвания класса Dataset

Загрузим обучающий набор данных, получим произвольное изображение с меткой. После чего визуализируем изображение, выведем метку. В будущем, этот кусок кода можно закомментировать или убрать.

[ ] *Скрыта 1 ячейка.*

Загрузка датасетов

[ ] *Скрыто 4 ячейки.*

Класс Metrics

Реализует метрики точности, используемые для оценивания модели:

1. точность,
2. сбалансированную точность.

```
class Metrics:

    @staticmethod
    def accuracy(gt: List[int], pred: List[int]):
        print(len(gt),len(pred))
        assert len(gt) == len(pred), 'gt and prediction should be of equal length'
        return np.sum([int(i[0] == i[1]) for i in zip(gt, pred)]) / len(gt)

    @staticmethod
    def accuracy_balanced(gt: List[int], pred: List[int]):
        return balanced_accuracy_score(gt, pred)

    @staticmethod
    def print_all(gt: List[int], pred: List[int], info: str):
        print(f'metrics for {info}:')
        print('\t accuracy {:.4f}:'.format(Metrics.accuracy(gt, pred)))
        print('\t balanced accuracy {:.4f}:'.format(Metrics.accuracy_balanced(gt, pred)))
```

Класс Model

Класс, хранящий в себе всю информацию о модели.

Вам необходимо реализовать методы save, load для сохранения и заргрузки модели. Особенно актуально это будет во время тестирования на дополнительных наборах данных.

> *Пожалуйста, убедитесь, что сохранение и загрузка модели работает корректно. Для этого обучите модель, протестируйте, сохраните ее в файл, перезапустите среду выполнения, загрузите обученную модель из файла, вновь протестируйте ее на тестовой выборке и убедитесь в том, что получаемые метрики совпадают с полученными для тестовой выбрки ранее.*

Также, Вы можете реализовать дополнительные функции, такие как:

1. валидацию модели на части обучающей выборки;
2. использование кроссвалидации;
3. автоматическое сохранение модели при обучении;
4. загрузку модели с какой-то конкретной итерации обучения (если используется итеративное обучение);
5. вывод различных показателей в процессе обучения (например, значение функции потерь на каждой эпохе);
6. построение графиков, визуализирующих процесс обучения (например, график зависимости функции потерь от номера эпохи обучения);
7. автоматическое тестирование на тестовом наборе/наборах данных после каждой эпохи обучения (при использовании итеративного обучения);
8. автоматический выбор гиперпараметров модели во время обучения;
9. сохранение и визуализацию результатов тестирования;

10. Использование аугментации и других способов синтетического расширения набора данных (дополнительным плюсом будет обоснование необходимости и обоснование выбора конкретных типов аугментации)
11. и т.д.

Полный список опций и дополнений приведен в презентации с описанием задания.

При реализации дополнительных функций допускается добавление параметров в существующие методы и добавление новых методов в класс модели.

```
input_shape = img.shape


class Model:

    def __init__(self):
     #VGG11
        network = tf.keras.models.Sequential()
        network.add(tf.keras.layers.Conv2D(64, (3,3), padding='same', input_shape=input_shape,
             kernel_initializer='he_uniform'
             ))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.MaxPooling2D())

        network.add(tf.keras.layers.Conv2D(128, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.MaxPooling2D())

        network.add(tf.keras.layers.Conv2D(256, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.Conv2D(256, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.MaxPooling2D())

        network.add(tf.keras.layers.Conv2D(512, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.Conv2D(512, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.MaxPooling2D())

        network.add(tf.keras.layers.Conv2D(512, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.Conv2D(512, (3,3), padding='same', kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.BatchNormalization())
        network.add(tf.keras.layers.ReLU())
        network.add(tf.keras.layers.MaxPooling2D())

        network.add(tf.keras.layers.Flatten())
        network.add(tf.keras.layers.Dense(512, activation='relu',
                       kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.Dense(4096, activation='relu',
                       kernel_initializer='he_uniform'))
        network.add(tf.keras.layers.Dense(9, activation='softmax',
            kernel_initializer='he_uniform'))

        self.network = network

    def save(self, name: str):
        filename = "/content/drive/MyDrive/" + name + '.h5'
        self.network.save_weights(filename, save_format='h5')

    def load(self, name: str):
    # example demonstrating loading the model with name 'name' from gdrive using link
        name_to_id_dict = {
            'first.h5': '1KZEotWMp0y9cZcPDNCo1kxbgL83Jl0tE',
            'second.h5': '1-4LFSOYNupSOwzYwO8xa4qrJ72FJlG92',
            'best.h5': '1-62bXygfhc9Dfuu5XtcIqHTxev4mBMBT'
        }
        url = f'https://drive.google.com/uc?id={name_to_id_dict[name]}'
        gdown.download(url, quiet=True, output=name, use_cookies=False)
        self.network.load_weights(name)

    def train(self, dataset: Dataset, batch_size, epochs):
        print(f'training started')
        x = dataset.images
```

```
        y = dataset.labels
        opt = tf.keras.optimizers.Adam(learning_rate=0.001)
        self.network.compile(optimizer=opt, loss=tf.keras.losses.sparse_categorical_crossentropy, metrics=['accuracy'])
        history = self.network.fit(x, y, batch_size, epochs, #validation_split=0.0, validation_data=None,
                        shuffle=True #validation_steps=None, validation_batch_size=None, validation_freq=1,
        )
        print(f'training done')
        self.history = history
        return history

    def test_on_dataset(self, dataset: Dataset, limit=None):
        # you can upgrade this code if you want to speed up testing using batches
        predictions = []
        n = dataset.n_files if not limit else int(dataset.n_files * limit)
        for img in tqdm(dataset.images_seq(n), total=n):
            predictions.append(self.test_on_image(img))
        return predictions

    def test_on_image(self, img: np.ndarray):
        prediction_prob = self.network.predict(img.reshape(1, 224, 224, 3), verbose=0)
        prediction = np.argmax(prediction_prob[0])
        return prediction
```

Классификация изображений

В качестве валидационной выборки буду использовать tiny_test. Модель обучается на наборе данных train.

Вспомогательные функции загрузки и построения графика функции потерь выведены из класса

```
def show_loss_per_iter(model, num_iter):
    fig, ax = plt.subplots(1, figsize=(8,6))
    losses = model.history.history['loss']
    num_epochs = len(losses)
    ax.plot(range(num_iter), losses, label="Triplet Loss")
    plt.xlabel("номер эпохи")
    plt.ylabel("Triplet Loss")
    plt.show()


EVALUATE_ONLY = False
```

Обучение с демонстрацией графиков функции потерь

```
model2 = Model()
if not EVALUATE_ONLY:
    history = model2.train(d_train, 100, 20)
    model2.save('first')
else:
    model2.load('best.h5')
```

```
 training started
 Epoch 1/20
 180/180 [==============================] - 189s 870ms/step - loss: 3.8412 - accuracy: 0.4296
 Epoch 2/20
 180/180 [==============================] - 157s 873ms/step - loss: 0.9082 - accuracy: 0.6487
 Epoch 3/20
 180/180 [==============================] - 157s 873ms/step - loss: 0.8097 - accuracy: 0.7017
 Epoch 4/20
 180/180 [==============================] - 157s 873ms/step - loss: 0.6572 - accuracy: 0.7651
 Epoch 5/20
 180/180 [==============================] - 157s 874ms/step - loss: 0.5506 - accuracy: 0.8141
 Epoch 6/20
 180/180 [==============================] - 157s 874ms/step - loss: 0.4416 - accuracy: 0.8580
 Epoch 7/20
 180/180 [==============================] - 158s 877ms/step - loss: 0.3856 - accuracy: 0.8776
 Epoch 8/20
 180/180 [==============================] - 158s 875ms/step - loss: 0.3431 - accuracy: 0.8928
 Epoch 9/20
 180/180 [==============================] - 158s 876ms/step - loss: 0.2880 - accuracy: 0.9082
 Epoch 10/20
 180/180 [==============================] - 158s 875ms/step - loss: 0.2615 - accuracy: 0.9195
 Epoch 11/20
 180/180 [==============================] - 158s 877ms/step - loss: 0.2281 - accuracy: 0.9298
 Epoch 12/20
 180/180 [==============================] - 157s 874ms/step - loss: 0.2204 - accuracy: 0.9325
 Epoch 13/20
 180/180 [==============================] - 158s 877ms/step - loss: 0.2180 - accuracy: 0.9346
 Epoch 14/20
```

```
180/180 [==============================] - 158s 876ms/step - loss: 0.1885 - accuracy: 0.9433
Epoch 15/20
180/180 [==============================] - 158s 876ms/step - loss: 0.1616 - accuracy: 0.9492
Epoch 16/20
180/180 [==============================] - 158s 877ms/step - loss: 0.2083 - accuracy: 0.9407
Epoch 17/20
180/180 [==============================] - 158s 875ms/step - loss: 0.1800 - accuracy: 0.9448
Epoch 18/20
180/180 [==============================] - 158s 876ms/step - loss: 0.1488 - accuracy: 0.9542
Epoch 19/20
180/180 [==============================] - 158s 875ms/step - loss: 0.1656 - accuracy: 0.9476
Epoch 20/20
180/180 [==============================] - 157s 874ms/step - loss: 0.1469 - accuracy: 0.9544
training done
```

```
#LBL1
show_loss_per_iter(model2, 20)
```

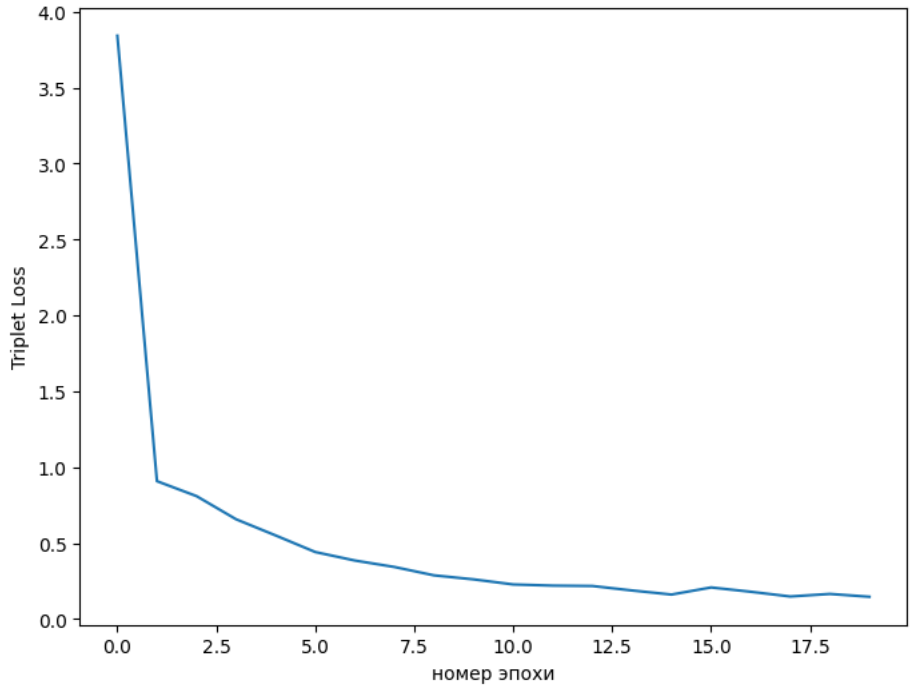


```
model2 = Model()
model2.load('first.h5')
```

```
pred_2 = model2.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred_2, '100% of tiny test')
```

```
100%                                                  90/90 [00:56<00:00, 2.71it/s]
metrics for 100% of tiny test:
90 90
         accuracy 0.3556:
         balanced accuracy 0.3556:
```

Модель недообучилась, дообучу модель еще на 20 эпохах.

```
model3 = Model()
model3.load('first.h5')
history3 = model3.train(d_train, 100, 20)
model3.save('second')
```

```
training started
Epoch 1/20
180/180 [==============================] - 190s 869ms/step - loss: 0.2032 - accuracy: 0.9418
Epoch 2/20
180/180 [==============================] - 156s 865ms/step - loss: 0.2241 - accuracy: 0.9323
Epoch 3/20
180/180 [==============================] - 156s 867ms/step - loss: 0.1932 - accuracy: 0.9420
Epoch 4/20
180/180 [==============================] - 156s 865ms/step - loss: 0.1146 - accuracy: 0.9621
Epoch 5/20
180/180 [==============================] - 156s 868ms/step - loss: 0.1635 - accuracy: 0.9496
Epoch 6/20
180/180 [==============================] - 156s 866ms/step - loss: 0.1304 - accuracy: 0.9559
Epoch 7/20
180/180 [==============================] - 156s 868ms/step - loss: 0.1029 - accuracy: 0.9678
```

```
Epoch 8/20
180/180 [==============================] - 156s 866ms/step - loss: 0.0951 - accuracy: 0.9695
Epoch 9/20
180/180 [==============================] - 156s 868ms/step - loss: 0.1359 - accuracy: 0.9576
Epoch 10/20
180/180 [==============================] - 156s 866ms/step - loss: 0.2062 - accuracy: 0.9351
Epoch 11/20
180/180 [==============================] - 156s 867ms/step - loss: 0.1334 - accuracy: 0.9582
Epoch 12/20
180/180 [==============================] - 156s 866ms/step - loss: 0.1196 - accuracy: 0.9614
Epoch 13/20
180/180 [==============================] - 156s 867ms/step - loss: 0.0979 - accuracy: 0.9668
Epoch 14/20
180/180 [==============================] - 156s 868ms/step - loss: 0.0984 - accuracy: 0.9697
Epoch 15/20
180/180 [==============================] - 156s 867ms/step - loss: 0.0776 - accuracy: 0.9752
Epoch 16/20
180/180 [==============================] - 156s 866ms/step - loss: 0.0793 - accuracy: 0.9743
Epoch 17/20
180/180 [==============================] - 156s 867ms/step - loss: 0.0660 - accuracy: 0.9790
Epoch 18/20
180/180 [==============================] - 156s 866ms/step - loss: 0.0724 - accuracy: 0.9762
Epoch 19/20
180/180 [==============================] - 156s 868ms/step - loss: 0.0700 - accuracy: 0.9776
Epoch 20/20
180/180 [==============================] - 156s 867ms/step - loss: 0.0604 - accuracy: 0.9812
training done
```

```
#LBL2
show_loss_per_iter(model3, 20)
```

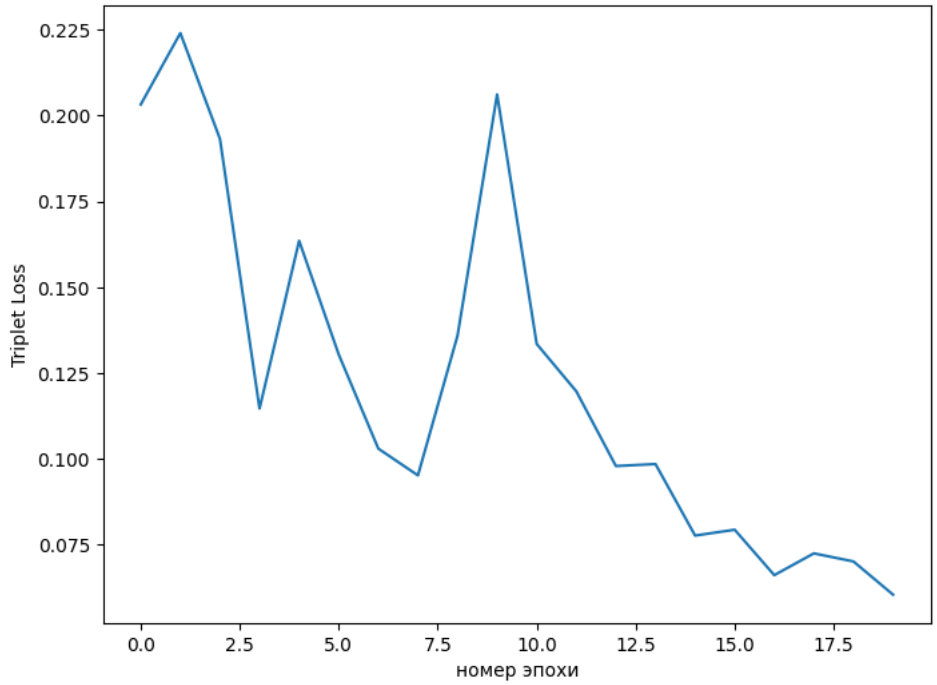


```
model2.load('second.h5')
pred_3 = model2.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred_3, '100% of tiny test')
```

```
100%                                                  90/90 [00:37<00:00, 2.78it/s]
metrics for 100% of tiny test:
90 90
         accuracy 0.7667:
         balanced accuracy 0.7667:
```

Желаемая точность достигнута, но функция потерь еще уменьшается, обучу еще на 20 эпохах.

```
model4 = Model()
model4.load('second.h5')
history4 = model4.train(d_train, 100, 20)
model4.save('best')
```

```
training started
Epoch 1/20
180/180 [==============================] - 191s 873ms/step - loss: 0.0960 - accuracy: 0.9714
Epoch 2/20
180/180 [==============================] - 156s 869ms/step - loss: 0.1727 - accuracy: 0.9643
```

```
Epoch 3/20
180/180 [==============================] - 156s 869ms/step - loss: 0.1219 - accuracy: 0.9674
Epoch 4/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0663 - accuracy: 0.9792
Epoch 5/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0616 - accuracy: 0.9804
Epoch 6/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0556 - accuracy: 0.9827
Epoch 7/20
180/180 [==============================] - 156s 868ms/step - loss: 0.0831 - accuracy: 0.9820
Epoch 8/20
180/180 [==============================] - 157s 870ms/step - loss: 0.0738 - accuracy: 0.9806
Epoch 9/20
180/180 [==============================] - 156s 868ms/step - loss: 0.1060 - accuracy: 0.9677
Epoch 10/20
180/180 [==============================] - 157s 870ms/step - loss: 0.0569 - accuracy: 0.9816
Epoch 11/20
180/180 [==============================] - 157s 870ms/step - loss: 0.0521 - accuracy: 0.9836
Epoch 12/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0519 - accuracy: 0.9827
Epoch 13/20
180/180 [==============================] - 157s 870ms/step - loss: 0.0493 - accuracy: 0.9827
Epoch 14/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0852 - accuracy: 0.9729
Epoch 15/20
180/180 [==============================] - 156s 868ms/step - loss: 0.0647 - accuracy: 0.9788
Epoch 16/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0548 - accuracy: 0.9814
Epoch 17/20
180/180 [==============================] - 157s 870ms/step - loss: 0.0480 - accuracy: 0.9831
Epoch 18/20
180/180 [==============================] - 156s 869ms/step - loss: 0.0392 - accuracy: 0.9876
Epoch 19/20
180/180 [==============================] - 157s 871ms/step - loss: 0.0561 - accuracy: 0.9828
Epoch 20/20
180/180 [==============================] - 156s 868ms/step - loss: 0.0624 - accuracy: 0.9821
training done
```

```
#LBL3
show_loss_per_iter(model4, 20)
```

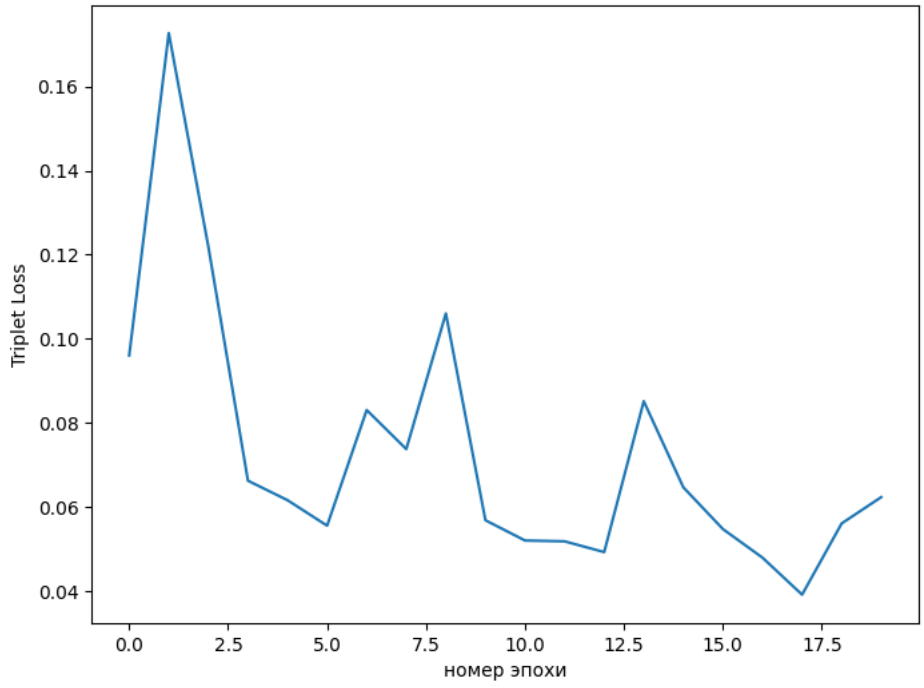


```
#LBL4
model2.load('best.h5')
pred_3 = model2.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred_3, '100% of tiny test')
```

```
100%                                          90/90 [00:36<00:00, 2.95it/s]
metrics for 100% of tiny test:
90 90
        accuracy 0.8111:
        balanced accuracy 0.8111:
```

Протестирую обученную модель на остальных тестовых наборах данных.

```
#LBL5
pred_4 = model2.test_on_dataset(d_test_small)
Metrics.print_all(d_test_small.labels, pred_4, '100% of small test')
```

```
100%                                                1800/1800 [12:47<00:00, 2.46it/s]
metrics for 100% of small test:
1800 1800
        accuracy 0.7911:
        balanced accuracy 0.7911:
```

```
#LBL6
pred_4 = model2.test_on_dataset(d_test)
Metrics.print_all(d_test.labels, pred_4, '100% of full train')
```

```
100%                                                4500/4500 [31:18<00:00, 2.84it/s]
metrics for 100% of full train:
4500 4500
        accuracy 0.7949:
        balanced accuracy 0.7949:
```

Построю матрицу ошибок для набора данных train.

```
#LBL7
from sklearn.metrics import confusion_matrix
import seaborn as sns

y_pred = pred_4
y_true = d_test.labels
cm = confusion_matrix(y_true, y_pred,normalize='true')
sns.heatmap(cm)
```

```
<Axes: >
```

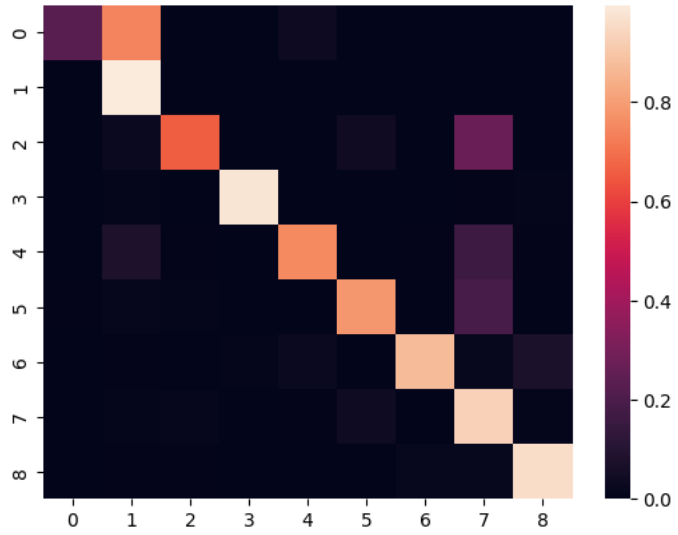


```
sensivity = np.diag(cm) / np.sum(cm, axis=0)
sum = np.sum(cm)
sum_row = np.sum(cm, axis=0)
sum_col = np.sum(cm, axis=1)
specificity = [(sum - sum_row[j] - sum_col[j] + cm[j][j]) / (sum - sum_col[j]) for j in range(9)]
```

```
print(cm)
```

```
[[0.226 0.74  0.002 0.    0.032 0.    0.    0.    0.   ]
 [0.    0.996 0.002 0.    0.002 0.    0.    0.    0.   ]
 [0.    0.024 0.66  0.    0.    0.04  0.002 0.272 0.002]
 [0.    0.008 0.    0.978 0.    0.    0.002 0.004 0.008]
 [0.    0.074 0.006 0.    0.754 0.002 0.004 0.156 0.004]
 [0.004 0.014 0.01  0.    0.    0.784 0.    0.188 0.   ]
 [0.    0.004 0.002 0.008 0.026 0.    0.872 0.016 0.072]
 [0.    0.008 0.014 0.    0.004 0.038 0.    0.926 0.01 ]
 [0.    0.006 0.004 0.    0.    0.    0.016 0.016 0.958]]
```

```
print(sensivity)
```

```
[0.9826087  0.53148346 0.94285714 0.99188641 0.92176039 0.90740741
 0.97321429 0.58681876 0.90891841]
```

```
print(specificity)
```

```
[0.9994999999999999, 0.89025, 0.9950000000000001, 0.9989999999999999, 0.992, 0.9899999999999999, 0.9969999999999999, 0.9185, 0.988]
```

Вывод: Модель довольно часто путает 0 и 1 класс, выдавая метку "1" для изображений класса "0". Так же происходит и с "7" классом, чью метку часто модель выявляет для изображений "2", "4" и "5" классов.

Визуально 0 и 1 классы оказались не похожи, поэтому сложно оценить, почему модель их путает. В отличии от пар классов 7, 5 и 7, 4, которые имеют схожую текстуру, и ошибки можно считать в какой-то степени схожими с человеческими.

```
print("0 класс")
for i in range(5):
    img0 = d_train.images[d_train.labels == 0][i]
    pil_img = Image.fromarray(img0)
    IPython.display.display(pil_img)
```

```
0 класс
```

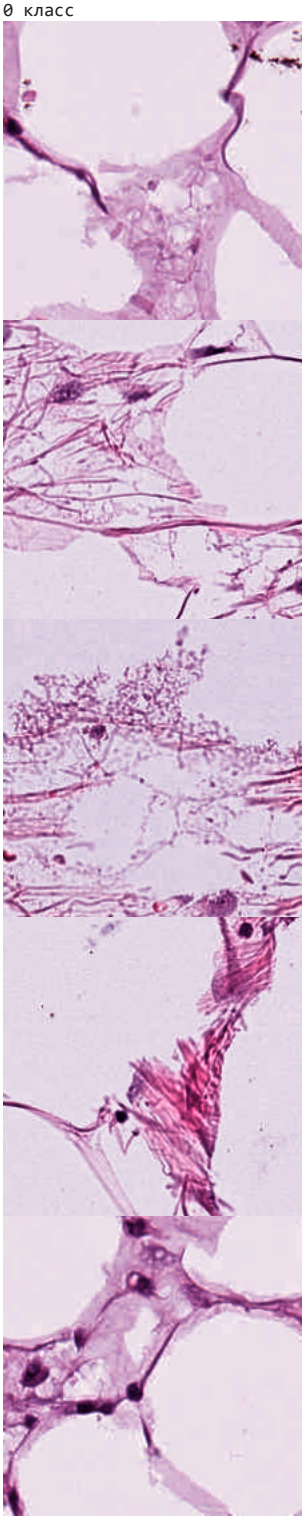

```
print("1 класс")
for i in range(5):
    img0 = d_train.images[d_train.labels == 1][i]
    pil_img = Image.fromarray(img0)
    IPython.display.display(pil_img)
```

```
1 класс
```

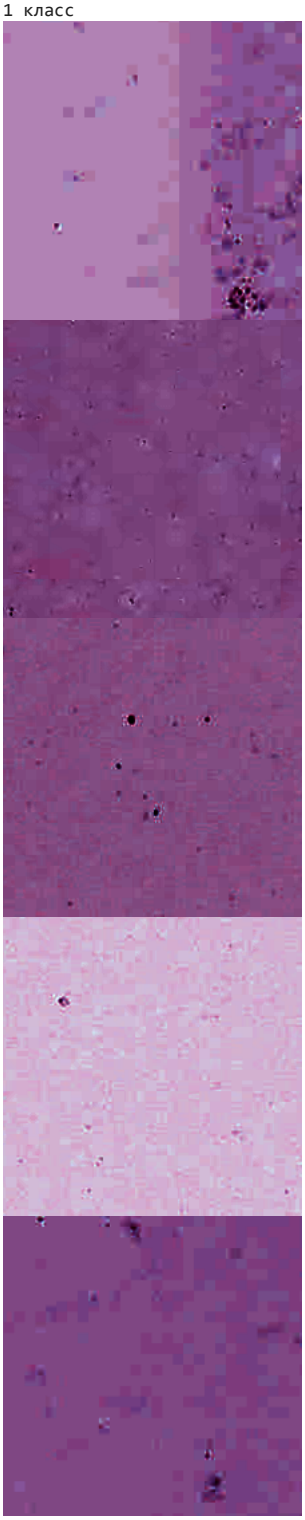

```
print("7 класс")
for i in range(5):
    img0 = d_train.images[d_train.labels == 7][i]
    pil_img = Image.fromarray(img0)
    IPython.display.display(pil_img)
```

```
7 класс
```

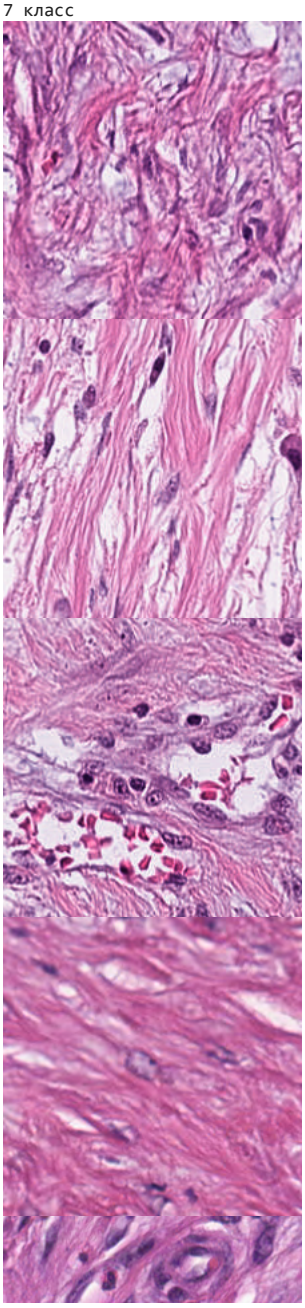

```
print("2 класс")
for i in range(5):
    img0 = d_train.images[d_train.labels == 2][i]
    pil_img = Image.fromarray(img0)
    IPython.display.display(pil_img)
```

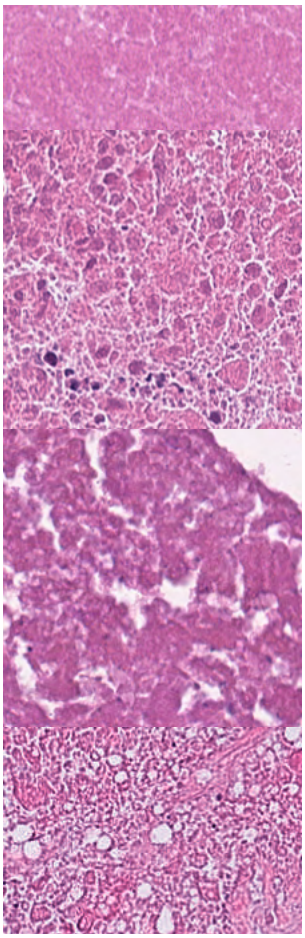

```
print("4 класс")
for i in range(5):
    img0 = d_train.images[d_train.labels == 4][i]
    pil_img = Image.fromarray(img0)
    IPython.display.display(pil_img)
```

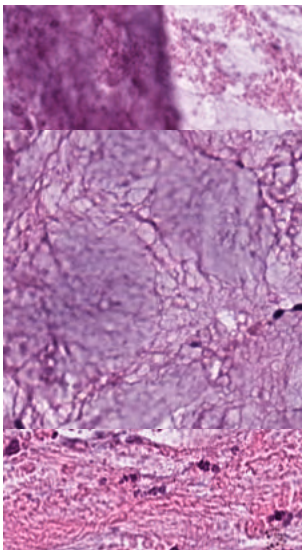

```
print("5 класс")
for i in range(5):
    img0 = d_train.images[d_train.labels == 5][i]
    pil_img = Image.fromarray(img0)
    IPython.display.display(pil_img)
```

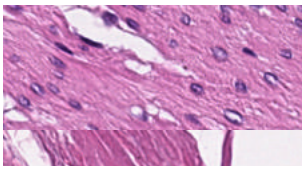

Результат работы пайплайна обучения и тестирования выше тоже будет оцениваться. Поэтому не забудьте присылать на проверку ноутбук с выполненными ячейками кода с демонстрациями метрик обучения, графиками и т.п. В этом пайплайне Вам необходимо продемонстрировать работу всех реализованных дополнений, улучшений и т.п.

Настоятельно рекомендуется после получения пайплайна с полными результатами обучения экспортировать ноутбук в pdf (файл -> печать) и прислать этот pdf вместе с самим ноутбуком.

Тестирование модели на других наборах данных

Ваша модель должна поддерживать тестирование на других наборах данных. Для удобства, Вам предоставляется набор данных test_tiny, который представляет собой малую часть (2% изображений) набора test. Ниже приведен фрагмент кода, который будет осуществлять тестирование для оценивания Вашей модели на дополнительных тестовых наборах данных.

Прежде чем отсылать задание на проверку, убедитесь в работоспособности фрагмента кода ниже.

```
final_model = Model()
final_model.load('best.h5')
d_test_tiny = Dataset('test_tiny')
pred = final_model.test_on_dataset(d_test_tiny)
Metrics.print_all(d_test_tiny.labels, pred, 'test-tiny')
```

```
Downloading...
From: https://drive.google.com/uc?export=download&confirm=pbef&id=1viiB0s041CNsAK4itv
To: /content/test_tiny.npz
100%|██████████| 10.6M/10.6M [00:00<00:00, 19.8MB/s]Loading dataset test_tiny from np
Done. Dataset test_tiny consists of 90 images.

100%                                                  90/90 [00:40<00:00, 2.90it/s]
metrics for test-tiny:
90 90
          accuracy 0.8111:
          balanced accuracy 0.8111:
```

Отмонтировать Google Drive.

```
drive.flush_and_unmount()
```

Дополнительные "полезности"

Ниже приведены примеры использования различных функций и библиотек, которые могут быть полезны при выполнении данного практического задания.

Измерение времени работы кода

Измерять время работы какой-либо функции можно легко и непринужденно при помощи функции timeit из соответствующего модуля:

[ ] *Скрыта 1 ячейка.*

Scikit-learn

Для использования "классических" алгоритмов машинного обучения рекомендуется использовать библиотеку scikit-learn (https://scikit-learn.org/stable/). Пример классификации изображений цифр из набора данных MNIST при помощи классификатора SVM:

[ ] *Скрыта 1 ячейка.*

Scikit-image

Реализовывать различные операции для работы с изображениями можно как самостоятельно, работая с массивами numpy, так и используя специализированные библиотеки, например, scikit-image (https://scikit-image.org/). Ниже приведен пример использования

Canny edge detector.

[ ] ↳ *Скрыта 1 ячейка.*

Tensorflow 2

Для создания и обучения нейросетевых моделей можно использовать фреймворк глубокого обучения Tensorflow 2. Ниже приведен пример простейшей нейроной сети, использующейся для классификации изображений из набора данных MNIST.

[ ] ↳ *Скрыто 4 ячейки.*

Numba

В некоторых ситуациях, при ручных реализациях графовых алгоритмов, выполнение многократных вложенных циклов for в python можно существенно ускорить, используя JIT-компилятор Numba (https://numba.pydata.org/). Примеры использования Numba в Google Colab можно найти тут:

1. https://colab.research.google.com/github/cbernet/maldives/blob/master/numba/numba_cuda.ipynb
2. https://colab.research.google.com/github/evaneschneider/parallel-programming/blob/master/COMPASS_gpu_intro.ipynb

> Пожалуйста, если Вы решили использовать Numba для решения этого практического задания, еще раз подумайте, нужно ли это Вам, и есть ли возможность реализовать требуемую функциональность иным способом. Используйте Numba только при реальной необходимости.

Работа с zip архивами в Google Drive

Запаковка и распаковка zip архивов может пригодиться при сохранении и загрузки Вашей модели. Ниже приведен фрагмент кода, иллюстрирующий помещение нескольких файлов в zip архив с последующим чтением файлов из него. Все действия с директориями, файлами и архивами должны осущетвляться с примонтированным Google Drive.

[ ] ↳ *Скрыто 4 ячейки.*